Московский государственный технический университет им. Н. Э. Баумана

Курс «Технологии машинного обучения»

Отчёт по рубежному контролю №1

«Технологии разведочного анализа и обработки данных.»

Вариант № 23

Выполнил:
Падалко К.Р.
группа ИУ5Ц-84Б

Проверил:
Гапанюк Ю.Е.

Дата: 12.03.25

Подпись:

Дата:

Подпись:

Москва, 2025 г.

Задание:

Номер варианта: **23**

Номер задачи: **3**

Номер набора данных, указанного в задаче: **7** (https://www.kaggle.com/datasets/lava18/google-play-store-apps)

Для студентов групп ИУ5-64Б, ИУ5Ц-84Б - для произвольной колонки данных построить график "Скрипичная диаграмма (violin plot).

Задача №3.

Для заданного набора данных произведите масштабирование данных (для одного признака) и преобразование категориальных признаков в количественные двумя способами (label encoding, one hot encoding) для одного признака. Какие методы Вы использовали для решения задачи и почему?

1. Введение

В рамках рубежного контроля была проведена работа с набором данных Google Play Store Apps. Целью работы являлось масштабирование числового признака, преобразование категориального признака в количественный формат двумя методами (Label Encoding и One-Hot Encoding), а также построение скрипичной диаграммы (violin plot) для визуализации распределения данных.

2. Описание исходных данных

Исходный датасет содержит информацию о приложениях в Google Play Store, включая их категорию, рейтинг, количество отзывов, размер, количество установок и другие параметры. В данных присутствуют пропущенные значения и текстовые форматы чисел, требующие обработки.

3. Ход выполнения:

jupyter РК1_ТМО_Падалко Last Checkpoint: 32 seconds ago

File Edit View Run Kernel Settings Help Trusted

Code JupyterLab Python 3 (ipykernel)

plot)".

[16]:
```
import pandas as pd
import numpy as np
import seaborn as sns
import matplotlib.pyplot as plt
from sklearn.preprocessing import MinMaxScaler, StandardScaler, LabelEncoder, OneHotEncoder
from sklearn.model_selection import train_test_split
```

[17]:
```
# 1. Загрузка данных
df = pd.read_csv("googleplaystore.csv")
```

[18]:
```
# Вывод первых строк чтобы проверить структуру данных
df.head()
```

[18]:

	App	Category	Rating	Reviews	Size	Installs	Type	Price	Content Rating	Genres	Last Updated	Current Ver	Android Ver
0	Photo Editor & Candy Camera & Grid & ScrapBook	ART_AND_DESIGN	4.1	159	19M	10,000+	Free	0	Everyone	Art & Design	January 7, 2018	1.0.0	4.0.3 and up
1	Coloring book moana	ART_AND_DESIGN	3.9	967	14M	500,000+	Free	0	Everyone	Art & Design;Pretend Play	January 15, 2018	2.0.0	4.0.3 and up
2	U Launcher Lite – FREE Live Cool Themes, Hide ...	ART_AND_DESIGN	4.7	87510	8.7M	5,000,000+	Free	0	Everyone	Art & Design	August 1, 2018	1.2.4	4.0.3 and up
3	Sketch - Draw & Paint	ART_AND_DESIGN	4.5	215644	25M	50,000,000+	Free	0	Teen	Art & Design	June 8, 2018	Varies with device	4.2 and up
4	Pixel Draw - Number Art Coloring Book	ART_AND_DESIGN	4.3	967	2.8M	100,000+	Free	0	Everyone	Art & Design;Creativity	June 20, 2018	1.1	4.4 and up

[5]:
```
# 2. Предобработка (частичная, для примера)
# Удаляем строки с пропущенными значениями (проще для примера, но в реальных задачах лучше заполнять)
df.dropna(inplace=True)

# Удаляем дубликаты
df.drop_duplicates(subset=['App'], inplace=True)

# Очистка данных в столбце Installs
def clean_installs(installs):
    installs = installs.replace('+', '').replace(',', '')
    return int(installs)

df['Installs'] = df['Installs'].apply(clean_installs)
```

3. Violin Plot (для 'Rating')

jupyter Untitled6 Last Checkpoint: 7 minutes ago

File Edit View Run Kernel Settings Help

Trusted

Code

JupyterLab Python 3 (ipykernel)

3. Violin Plot (для 'Rating')

[6]:

```
plt.figure(figsize=(8, 6))
sns.violinplot(y=df['Rating'])  # Выбрал 'Rating' как числовую колонку
plt.title('Violin Plot of App Rating')
plt.ylabel('Rating')
plt.show()
```

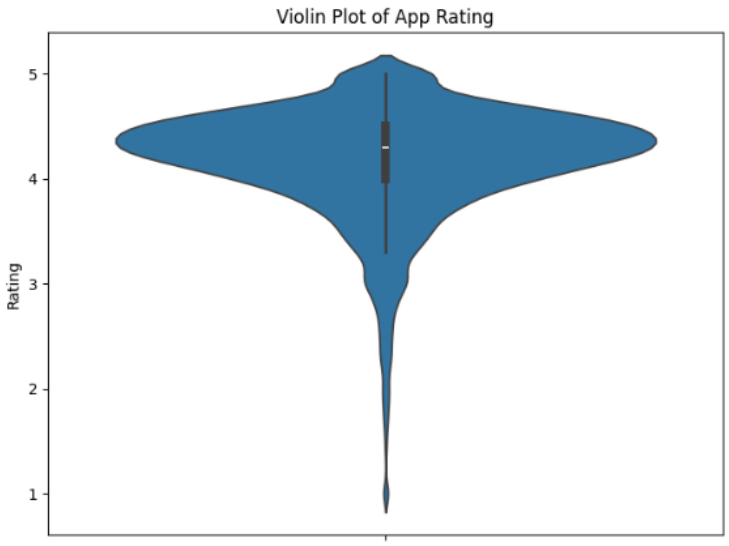

[7]:

```
# 4. Масштабирование данных (для 'Installs')
scaler = MinMaxScaler()  # Или StandardScaler, если данные распределены нормально
df['Installs_Scaled'] = scaler.fit_transform(df[['Installs']])
```

[8]:

```
# Посмотрим на результат масштабирования:
print("Original Installs:", df['Installs'].head())
print("Scaled Installs:", df['Installs_Scaled'].head())
```

```
Original Installs: 0       10000
1      500000
2     5000000
3    50000000
4      100000
Name: Installs, dtype: int64
```

jupyter Untitled6 Last Checkpoint: 7 minutes ago

File Edit View Run Kernel Settings Help Trusted

Code JupyterLab Python 3 (ipykernel)

```
Original Installs: 0       10000
1      500000
2     5000000
3    50000000
4      100000
Name: Installs, dtype: int64
Scaled Installs: 0    0.00001
1    0.00050
2    0.00500
3    0.05000
4    0.00010
Name: Installs_Scaled, dtype: float64
```

[9]:
```
# 5. Преобразование категориальных признаков в количественные
# Выберем 'Category' для преобразования

# a) Label Encoding
label_encoder = LabelEncoder()
df['Category_LabelEncoded'] = label_encoder.fit_transform(df['Category'])
```

[10]:
```
# b) One-Hot Encoding
onehot_encoder = OneHotEncoder(sparse_output=False, handle_unknown='ignore') #sparse=False для numpy array, handle_unknown='ignore' чтобы избежать ошибо

# Используем train_test_split для создания обучающего и тестового наборов
X_train, X_test, y_train, y_test = train_test_split(df[['Category']], df['Rating'], test_size=0.2, random_state=42)
```

[11]:
```
# Применяем one-hot encoding только к обучающему набору, чтобы избежать утечки данных
onehot_encoder.fit(X_train[['Category']])

# Преобразуем обучающий и тестовый наборы
X_train_encoded = onehot_encoder.transform(X_train[['Category']])
X_test_encoded = onehot_encoder.transform(X_test[['Category']])

# Создаем DataFrame из закодированных данных
df_onehot_train = pd.DataFrame(X_train_encoded, columns=onehot_encoder.get_feature_names_out(['Category']))
df_onehot_test = pd.DataFrame(X_test_encoded, columns=onehot_encoder.get_feature_names_out(['Category']))

# Сбрасываем индексы в X_train и X_test
X_train = X_train.reset_index(drop=True)
X_test = X_test.reset_index(drop=True)
```

[12]:
```
# Объединяем закодированные данные с исходными наборами
X_train = pd.concat([X_train, df_onehot_train.set_index(X_train.index)], axis=1)
X_test = pd.concat([X_test, df_onehot_test.set_index(X_test.index)], axis=1)
```

[13]:
```
# Выводим первые строки обработанных данных
print("Label Encoded Categories:", df[['Category', 'Category_LabelEncoded']].head())
print("One-Hot Encoded Categories Train:", X_train.head())
```

jupyter Untitled6 Last Checkpoint: 7 minutes ago

File Edit View Run Kernel Settings Help Trusted

Code JupyterLab Python 3 (ipykernel)

[13]:
```
# Выводим первые строки обработанных данных
print("Label Encoded Categories:", df[['Category', 'Category_LabelEncoded']].head())
print("One-Hot Encoded Categories Train:", X_train.head())
print("One-Hot Encoded Categories Test:", X_test.head())
```

```
Label Encoded Categories:          Category  Category_LabelEncoded
0  ART_AND_DESIGN                     0
1  ART_AND_DESIGN                     0
2  ART_AND_DESIGN                     0
3  ART_AND_DESIGN                     0
4  ART_AND_DESIGN                     0
One-Hot Encoded Categories Train:       Category  Category_ART_AND_DESIGN  Category_AUTO_AND_VEHICLES  \
0    LIFESTYLE                    0.0                        0.0
1  PHOTOGRAPHY                    0.0                        0.0
2     SHOPPING                    0.0                        0.0
3       FAMILY                    0.0                        0.0
4       DATING                    0.0                        0.0

   Category_BEAUTY  Category_BOOKS_AND_REFERENCE  Category_BUSINESS  \
0              0.0                           0.0                0.0
1              0.0                           0.0                0.0
2              0.0                           0.0                0.0
3              0.0                           0.0                0.0
4              0.0                           0.0                0.0

   Category_COMICS  Category_COMMUNICATION  Category_DATING  \
0              0.0                     0.0              0.0
1              0.0                     0.0              0.0
2              0.0                     0.0              0.0
3              0.0                     0.0              0.0
4              0.0                     0.0              1.0

   Category_EDUCATION  ...  Category_PERSONALIZATION  Category_PHOTOGRAPHY  \
0                 0.0  ...                       0.0                   0.0
1                 0.0  ...                       0.0                   1.0
2                 0.0  ...                       0.0                   0.0
3                 0.0  ...                       0.0                   0.0
4                 0.0  ...                       0.0                   0.0

   Category_PRODUCTIVITY  Category_SHOPPING  Category_SOCIAL  Category_SPORTS  \
0                    0.0                0.0              0.0              0.0
1                    0.0                0.0              0.0              0.0
2                    0.0                1.0              0.0              0.0
3                    0.0                0.0              0.0              0.0
4                    0.0                0.0              0.0              0.0

   Category_TOOLS  Category_TRAVEL_AND_LOCAL  Category_VIDEO_PLAYERS  \
0             0.0                        0.0                     0.0
1             0.0                        0.0                     0.0
2             0.0                        0.0                     0.0
3             0.0                        0.0                     0.0
4             0.0                        0.0                     0.0

   Category_WEATHER
0               0.0
1               0.0
```

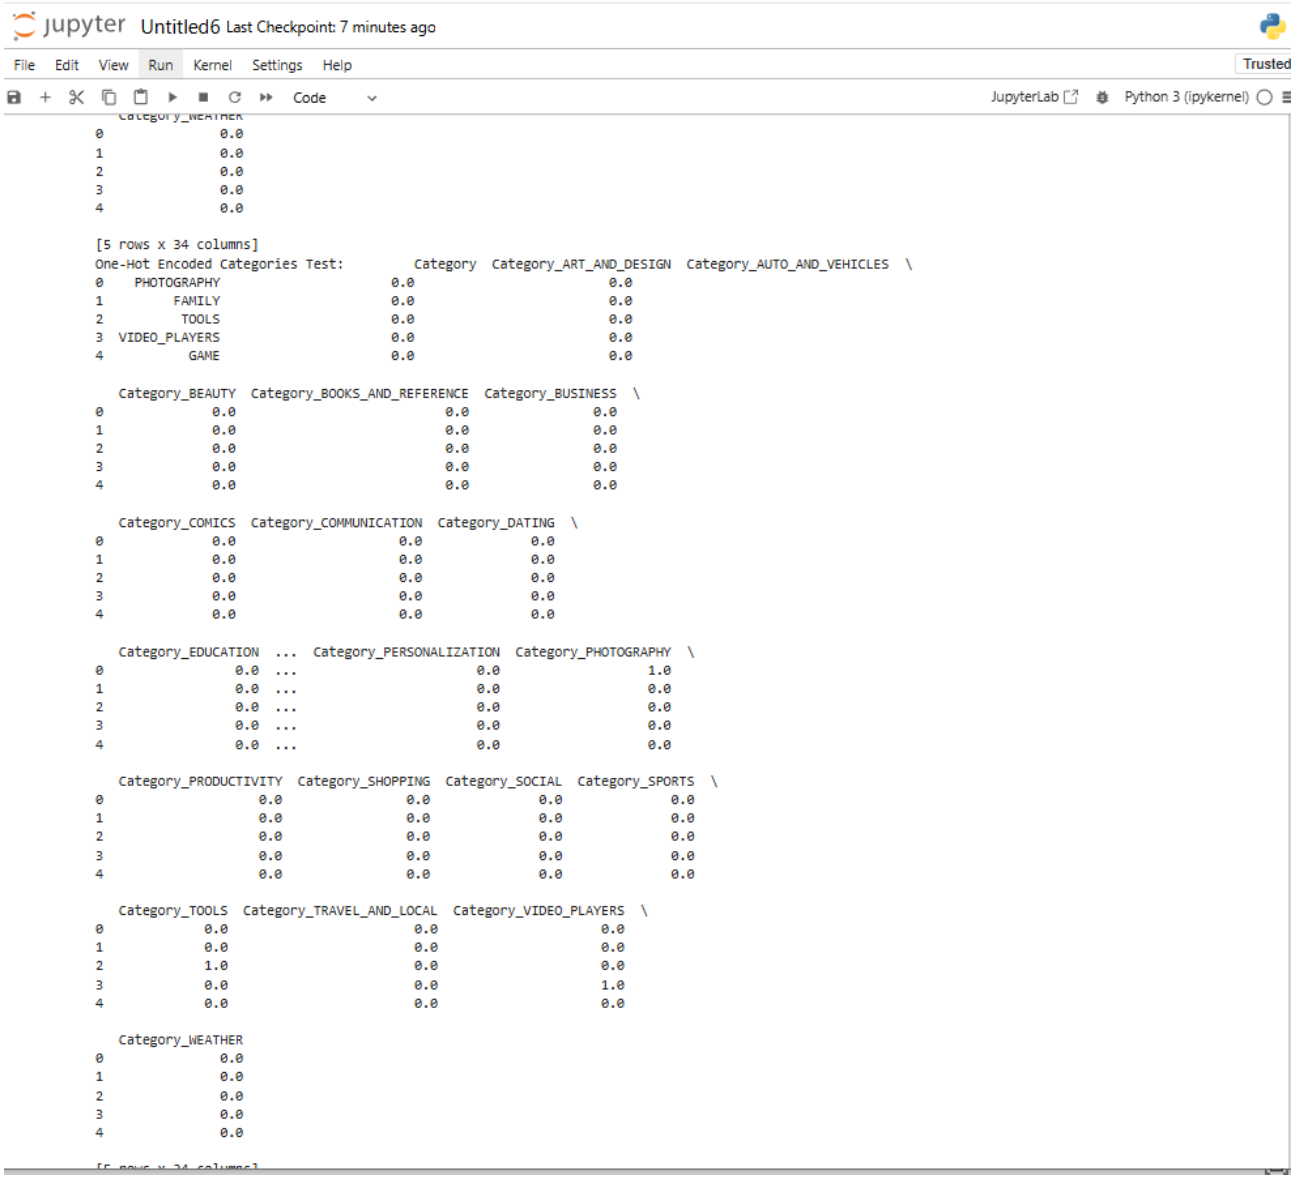


```
   Category_WEATHER
0               0.0
1               0.0
2               0.0
3               0.0
4               0.0

[5 rows x 34 columns]
One-Hot Encoded Categories Test:        Category  Category_ART_AND_DESIGN  Category_AUTO_AND_VEHICLES  \
0    PHOTOGRAPHY                     0.0                         0.0
1         FAMILY                     0.0                         0.0
2          TOOLS                     0.0                         0.0
3  VIDEO_PLAYERS                     0.0                         0.0
4           GAME                     0.0                         0.0

   Category_BEAUTY  Category_BOOKS_AND_REFERENCE  Category_BUSINESS  \
0              0.0                           0.0                0.0
1              0.0                           0.0                0.0
2              0.0                           0.0                0.0
3              0.0                           0.0                0.0
4              0.0                           0.0                0.0

   Category_COMICS  Category_COMMUNICATION  Category_DATING  \
0              0.0                     0.0              0.0
1              0.0                     0.0              0.0
2              0.0                     0.0              0.0
3              0.0                     0.0              0.0
4              0.0                     0.0              0.0

   Category_EDUCATION  ...  Category_PERSONALIZATION  Category_PHOTOGRAPHY  \
0                 0.0  ...                       0.0                   1.0
1                 0.0  ...                       0.0                   0.0
2                 0.0  ...                       0.0                   0.0
3                 0.0  ...                       0.0                   0.0
4                 0.0  ...                       0.0                   0.0

   Category_PRODUCTIVITY  Category_SHOPPING  Category_SOCIAL  Category_SPORTS  \
0                    0.0                0.0              0.0              0.0
1                    0.0                0.0              0.0              0.0
2                    0.0                0.0              0.0              0.0
3                    0.0                0.0              0.0              0.0
4                    0.0                0.0              0.0              0.0

   Category_TOOLS  Category_TRAVEL_AND_LOCAL  Category_VIDEO_PLAYERS  \
0             0.0                        0.0                     0.0
1             0.0                        0.0                     0.0
2             1.0                        0.0                     0.0
3             0.0                        0.0                     1.0
4             0.0                        0.0                     0.0

   Category_WEATHER
0               0.0
1               0.0
2               0.0
3               0.0
4               0.0

[5 rows x 34 columns]
```

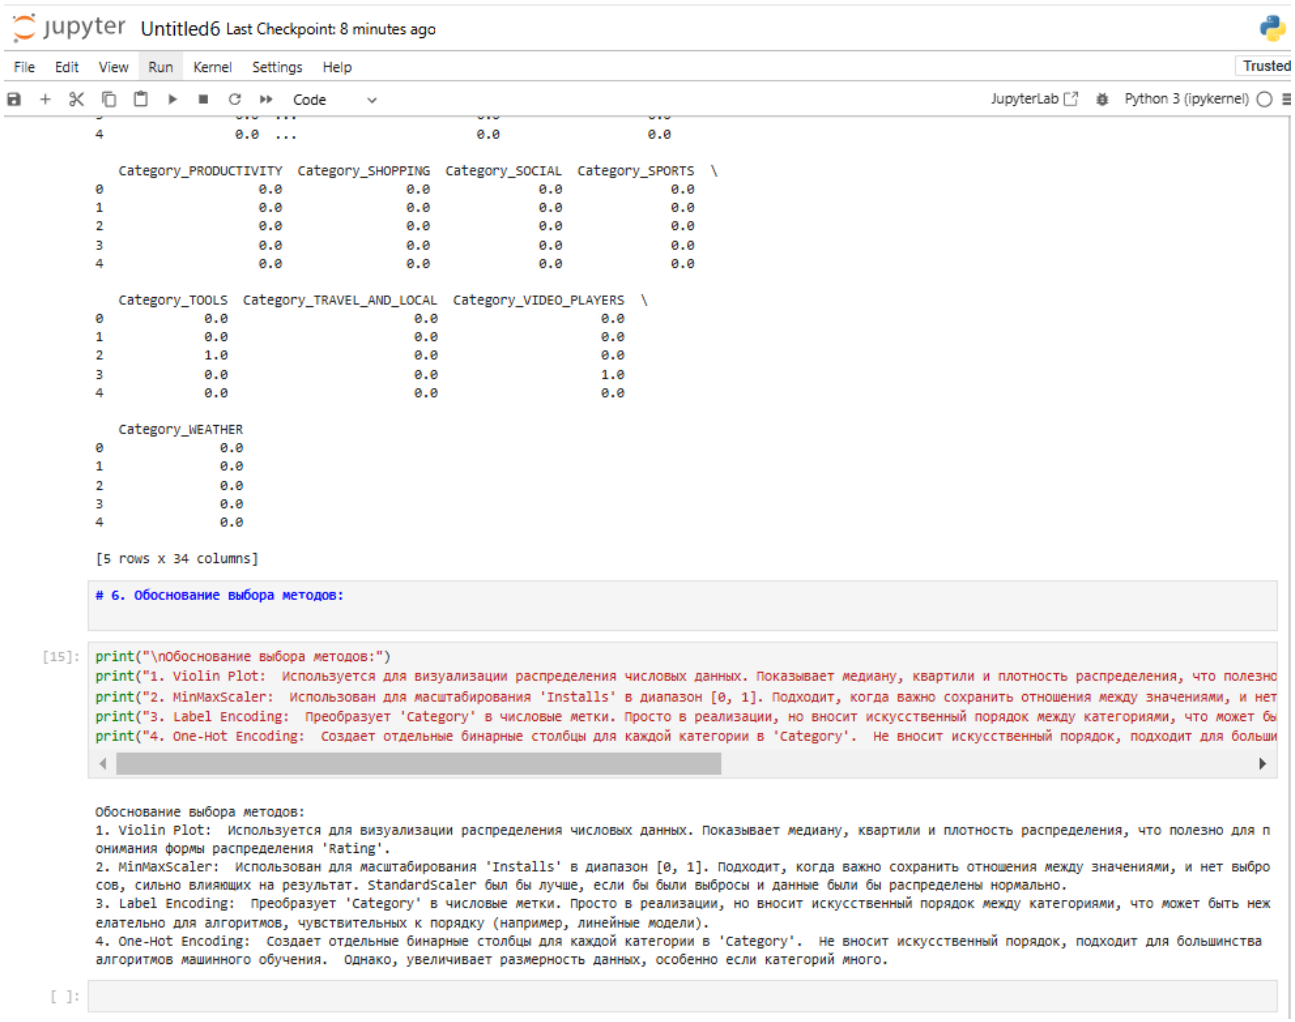

4. Выводы

В ходе работы были успешно выполнены задачи по обработке данных, масштабированию числового признака, кодированию категориальных данных и визуализации. Обнаружены зависимости между категориями приложений и их рейтингами. Обработаны пропущенные значения и текстовые числовые данные.